

应用数理统计方法

第五章 相关与回归分析

- 5.1 二元相关分析
- 5.2 多元相关分析
- 应用举例**
- 5.3 一元线性回归
- 5.4 其他回归方法
- 应用举例**

单变量与多变量研究

p.

▪ 总体与变量

总体: 研究总体中的全部个体

变量: 研究者关注的总体性质

▪ 单变量研究

参数估值 总体大小, 离散, 分布特征表征

假设检验 总体大小, 离散, 分布特征比较

▪ 多变量研究

方差分析 影响因素研究 假设检验

从两总体大小比较到方差分析 - 引入影响因素概念

相关分析 变量共变关系研究 参数估值与假设检验

回归分析 预测与估值模型 参数估值与假设检验

多变量研究方法对比

p.229,292

- 相关分析**
共变关系 两变量等价
- 回归分析**
模型构建 根据自变量估计或预测因变量
- 方差分析**
影响因素 判断变量是否受某些因素影响

多变量研究方法的关系

p.229,292-242

▪ 相关分析与回归分析

共同之处 研究两个或多个变量间关系, 数据格式相似

不同之处 研究目的, 变量关系, 变量类型, 统计量, 检验方法

▪ 方差分析与回归分析

共同之处 一变量对另一个变量的依赖, 变量类型

不同之处 研究目的, 变量关系, 结果表达, 统计量, 检验方法, 方法应用

方法	相关分析	回归分析	方差分析
研究目的	变量一起变化的程度	构建回归模型 - 估值或预测	研究影响因素
变量关系	两个独立变量	自变量与因变量	独立变量与影响因素
变量类型	均为随机变量	因变量随机, 自变量固定或随机	独立变量随机, 影响因素固定或随机
统计量	无量纲的相关系数	有单位的回归参数	无描述统计量
检验	相关是否显著	斜率是否显著, 模型选择	影响因素是否显著

多变量研究的数据

p.229,292-242

- 方差分析, 相关分析与回归分析数据比较**

方差分析 研究对象为随机变量, 影响因素固定或者随机

相关分析 两个随机变量

回归分析 无重复数据回归: 一个自变量取值对应一个因变量取值
有重复数据回归: 一个自变量取值对应一个以上因变量取值

相关分析 无重复数据回归 $X_i, Y_i, i=1 \dots n$	方差分析 有重复数据回归 $X_i, Y_{ij}, i=1 \dots n, j=1 \dots m$
$\begin{array}{ c c } \hline X_1 & Y_1 \\ \hline X_2 & Y_2 \\ \hline \dots & \dots \\ \hline X_n & Y_n \\ \hline \end{array}$	$\begin{array}{ c c c } \hline X_1 & Y_{11} & Y_{21} \dots Y_{m1} \\ \hline X_2 & Y_{12} & Y_{22} \dots Y_{m2} \\ \hline \dots & \dots & \dots \\ \hline X_n & Y_{1n} & Y_{2n} \dots Y_{mn} \\ \hline \end{array}$

相关与回归分析应用中的常见问题**▪ 混用相关分析与回归分析**

研究目的不明确 没有区分共变与预测

▪ 忽视变量的分布特征

对非正态分布数据使用参数相关 可能导致错误结论

回归分析中忽视数据分布特点 可能导致结果偏差

▪ 不区分因果关系与间接相关的差别

对显著相关的过度解释 错误解释相关结果, 导致对因果的误判

▪ 错误理解回归分析的检验结果

无重复数据的回归仅能检验斜率 不能判断模型优劣



应用数理统计方法

第五章 相关与回归分析

- 5.1 二元相关分析
- 5.2 多元相关分析
- 应用举例
- 5.3 一元线性回归
- 5.4 其他回归方法
- 应用举例

假设检验问题 p.63


- 特征比较
 - 两总体或多总体大小比较 2.2 – 2.5
 - 两总体或多总体离散程度比较 3.1 – 3.2
 - 两总体分布特征比较 3.4
 - 总体分布是否服从特定理论分布 3.3 – 3.4
- 影响因素
 - 方差分析及补充分析 4.1 – 4.4
- 变量关系
 - 相关分析 5.1 – 5.2
 - 回归分析 5.3 – 5.4

变量间相关关系 p.295

- 直接相关
 - 变量间有因果关系 如价格与销量, 暴露剂量与毒性
 - 因果关系需非统计证据 如苯并芘致癌的流调、动物实验, 临床、机理 ... 研究
- 间接相关
 - 受共同因素影响的共变 如人均收入与癌症发病率, 啤酒消费量与GDP
 - 避免过度解释, 环境健康研究中常见的关联
- 假相关
 - 互为衍生关系 如清洁能源占比与煤占比, 粘粒与沙粒占比
 - 没有意义

相关分析方法选择 p.296-297

- 研究目的
 - 确认探讨共变关系 属于相关问题?
- 变量
 - 确认均为随机变量 相关分析的必要前提
 - 确定变量个数 二元或多元相关?
 - 确定变量关系 是否为简单线性关系? 或需要作数据变换?
- 总体特征
 - 确认分布类型 参数或非参数方法
 - 是否需要作正态变换?



相关分析方法 p.296

- 参数与非参数方法
 - 参数方法 正态分布数据
 - 非参数方法 非正态分布数据
- 二元与多元
 - 二元相关 两变量共变
 - 多元相关 多变量共变
- 其它
 - 列联表分析 类型变量关联
 - 快速方法 简便, 但不严格

方法	二元相关	多元相关
参数方法	Pearson 相关系数	偏相关系数 复相关系数 典型相关分析
非参数方法	Spearman 秩相关系数 Kendall秩相关系数 双向列联表分析 象限相关分析 Lomstra-Tukey 偏角检验	Kendall 偏秩相关系数 Kendall 和谐系数 多向列联表分析

5.1.1

5.1.1 Pearson 相关系数及其显著性检验

5.1.2 Spearman 秩相关系数

二元正态分布

p.298

▪ 二元正态分布


两个正态分布总体的联合概率密度函数

Pearson 相关分析的必要前提

▪ 投影

与 x-z 或 y-z 平面平行的剖面上的切面为正态分布

在 x-y 平面投影为椭圆或圆



二元参数相关

p.296

▪ Pearson 相关系数

二元参数相关方法

方法	二元相关	多元相关
参数方法	Pearson 相关系数	5.1.1 偏相关系数 复相关系数 典型相关分析
非参数方法	Spearman 级相关系数	Kendall 偏秩相关系数 Kendall 和谐系数 双向列联表分析 象限相关分析 Lomstead-Tukey 偶角检验
	5.1.2 双向列联表分析	5.1.2 多向列联表分析

Pearson 相关系数

p.298-301

▪ 数据

服从二元正态分布

▪ Pearson 相关系数

表征两个随机变量的共变程度 一个发生变化, 另一个随之变化, 反之亦然
取值在 -1 到 1 之间 从负相关 -1 到不相关 0, 再到正相关 +1

▪ 正相关与负相关

正相关: 两变量共变方向相同

负相关: 两变量共变方向相反



偏离二元正态分布的可能影响

p.299


▪ 二元正态分布

Pearson 相关检验的必要前提

▪ 偏离二元正态分布的影响举例

个别异常的影响 剔除异常

多峰分布的影响 拆分总体



相关系数计算

p.299

▪ Pearson 相关系数计算

包括所有点 x_i, y_i 到 \bar{x}, \bar{y} 均值的距离

▪ 调整相关系数

修正样本量过小导致的样本相关系数对总体相关系数的偏差

▪ 相关系数取值

-1 完全负相关, 1 完全正相关, 0 完全不相关

需要检验与 0 是否有显著差异

相关系数的显著性检验

p.299-300

▪ 相关系数检验

总体相关系数是否与 0 有显著差别 即是否显著相关

与偏度-峰态系数检验类比

▪ 假设检验

双侧检验 $H_0 \rho = 0, H_1 \rho \neq 0$

单侧检验 $H_0 \rho = 0, H_1 \rho < 0$ 已知不可能为正相关

$H_1 \rho > 0$ 已知不可能为负相关

▪ 判断

直接判断 $p < \alpha$ 或 $p < 2\alpha$ 单侧检验

间接判断 $|r| > r_{\text{dft}}$ 或 $|r| > r_{2\alpha, n}$ 单侧检验

如果显著, 再根据计算值的正负号区分正相关/负相关

相关系数比较与公共相关系数

不要求 p.303-305

· 相关系数比较

比较两个或多个相关系数是否有显著差异

类比大小比较 $H_0: \rho_1 = \rho_2, H_1: \rho_1 \neq \rho_2$

· 检验

两个相关系数比较 $H_0: \rho_1 = \rho_2, H_1: \rho_1 \neq \rho_2$ 可选择单侧或双侧检验

多个相关系数比较 $H_0: \rho_i$ 都相同, $H_1: \rho_i$ 不都相同 无单双侧之分

· 公共相关系数

如果检验结果无显著差异, 可计算公共相关系数 计算略

5.1.2

5.1.1 Pearson 相关系数及其显著性检验

5.1.2 Spearman 秩相关系数

非参数相关检验方法

p.297

· 非参数相关检验

非二元正态分布总体 且不能做正态变换

非线性关系 且不能做线性变换

仅获得秩数据 数据变换的单向性

· 秩相关系数

Spearman 和 Kendall 检验 类似, 功效效率 91%

· 其它方法

列联系数 类型变量相关

快速检验 简便, 不严格

方法	二元相关		多元相关	
	参数方法	Pearson 相关系数	5.1.1	偏相关系数
				5.2
			复相关系数	5.2
			典型相关分析	
非参数方法	Spearman 秩相关系数	5.1.2	Kendall 偏秩相关系数	
	Kendall 秩相关系数		Kendall 和谐系数	
	双向列联表分析	5.1.2	多向列联表分析	
	象限相关分析			
	Lomax-Tukey 偶角检验			

Spearman 秩相关系数

p.308-310

· 应用

非二元正态分布数据 可尝试正态变换后用参数方法

非线性关系数据 可尝试线性变换后用参数方法

· 假设

双侧检验 $H_0: \text{两总体不相关}, H_1: \text{两总体相关}$

单侧检验 $H_0: \text{两总体不相关}, H_1: \text{两总体正相关或负相关}$

· 计算与判断

计算相伴概率 p 或 秩相关系数 r_s

直接判断 $p < \alpha$ 或 $p < 2\alpha$ 单侧检验

间接判断 $r_s \geq r_{\alpha[1,n-2]}$ 或 $r_{2\alpha[1,n-2]}$ 单侧检验

非线性相关

· 线性相关


计算 Pearson 相关系数

· 非线性相关

选择一 线性变换后, 计算 Pearson 相关系数

选择二 直接用非参数方法

· 线性化举例



双向列联表分析

不要求 p.313-315

· 双向列联表

X 与 Y 两个类型变量的频数表 f_{ij}

· 双变量列联表分析

检验两个类型变量的相关性, 即非独立性 简称双向表分析

· 方法

假设: $H_0: \text{两变量有独立性}, H_1: \text{两变量不具有独立性}$

计算: 两变量独立条件下的理论频数 \hat{f}_{ij}

根据观测频数 f_{ij} 和理论频数 \hat{f}_{ij} 计算列联系数 C

检验: 同拟合度卡方检验方法 参见 3.4.2

拒绝: $p < \alpha$ 或 $G \geq \chi^2_{\alpha[1]}$

X \ Y	1	2	...	k
1	f_{11}	f_{12}	...	f_{1k}
2	f_{21}	f_{22}	...	f_{2k}
...				
r	f_{r1}	f_{r2}	...	f_{rk}



应用数理统计方法

第五章 相关与回归分析

5.1 二元相关分析
5.2 多元相关分析
应用举例
5.3 一元线性回归
5.4 其他回归方法
应用举例

p.296

多元参数相关

· 偏相关与复相关

类似 Pearson 相关系数 涉及两个以上变量, 正态假设, 线性关系
偏相关: 在消除其他变量影响的前提下, 考察两个变量间共变关系
复相关: 考察一个变量与一组变量间的共变关系

· 典型相关

代表两组变量的两个综合变量间的相关关系 多元分析内容之一

方法	二元相关		多元相关	
	参数方法	Pearson 相关系数	5.1.1	偏相关系数 复相关系数
非参数方法	Spearman 秩相关系数 Kendall秩相关系数 双向列联表分析 聚类相关分析 Lomstead-Tukey 锥角检验	5.1.2	Kendall 偏秩相关系数 Kendall 和谐系数 多向列联表分析	5.2
				典型相关分析

偏相关系数 p.320-321

偏相关系数

· 偏相关

研究 k 个变量间的关系排除其它因素影响的两变量相关关系
固定 $v_3 \dots v_k$ 的前提下, $v_1 - v_2$ 间共变 相当于固定其它条件的实验设计
记为 $r_{12,3..k}$ 如 $r_{12,3}, r_{12,34}$
取值在 -1 到 +1 之间 与二元相关相同

· 检验

假设 $H_0 \rho_{12,3..k} = 0, H_1 \rho_{12,3..k} \neq 0$ 单侧 $\rho_{12,3..k} > 0, \rho_{12,3..k} < 0$
拒绝条件 $p < \alpha$ 或 $|r| \geq r_{\alpha[k,v]}$ 单侧 $p < 2\alpha$ 或 $|r| \geq r_{2\alpha[k,v]}$
如果显著, 再根据计算值的正负号确定正相关或负相关

复相关系数 p.322-323

复相关系数

· 复相关

研究一个变量与一组变量间共变 可依次研究每个变量与其它所有变量间关系
研究 v_1 与 $v_2 \dots v_k$ 的共变 局限性
记为 $R_{1,2..k}$ 如 $R_{1,2..3}, R_{1,2..4}$
取值在 0 到 1 之间 无正负相关之分
局限性 不能区分变量 2 .. k 的独立贡献
无单侧检验

· 检验

假设 H_0 复相关系数与 0 无显著差别, H_1 与 0 有显著差别
拒绝条件 $p < \alpha$ 或 $R \geq r_{\alpha[k,v]}$

Kendall 偏秩相关系数 p.325-326

Kendall 偏秩相关系数

· 偏秩相关

从 Kendall 秩相关系数演变而来
不要求多元正态分布, 不要求线性关系
表达类似偏相关系数, 如 $\tau_{12,3}$

· 方法局限

无显著性检验手段, 因此用途有限



应用数理统计方法

第五章 相关与回归分析

5.1 二元相关分析
5.2 多元相关分析
应用举例
5.3 一元线性回归
5.4 其他回归方法
应用举例

应用实例 巧克力与诺贝尔奖的关系

Messerli, New Eng. J. Med. 2015

问题与方法

背景: 可可中的黄烷醇可有效减缓年龄增长导致的认知功能下降
人均诺贝尔奖总数可在一定程度上衡量国家的整体认知功能?

研究: 研究巧克力消费与人均诺奖获奖人数的相关关系

检验与结果


假设: 人均巧克力消费量和人均诺奖获奖人数无关

结果: 检验结果显著

结论: 巧克力消费与整体认知水平正相关

讨论: 典型的间接相关无意义 隐含因果关系

经济、社会、教育、投入、积累...

**应用实例 影像分辨率对景观格局与地表温度关系的影响**

Li et al., LUP, 2013

问题与方法

问题: 地表温度与景观格局指标间关系 不同分辨率遥感影像 30m, 10m, 2.44m

绿地覆盖率、斑块面积、斑块密度、景观形状、边界密度、形状指数、邻域距离

研究: 数据分辨率对地表温度与相关指标相关关系的影响

检验与结果

计算: 偏相关系数 排除指标间相互影响, 比较不同分辨率结果

发现: 分辨率影响大部分指标, 影响方向各异

如: 分辨率越高, 绿地覆盖率与地表温度相关越显著, 高分辨率图像可以识别较小的斑块

**应用实例 牙周炎指标与口腔指标的关系**

Kim et al., KAOMS, 2021

问题与方法

问题: 影响牙周炎的主要口腔指标 BOP 是否与牙周炎有关

研究: 调集 84 例牙周炎患者测定 sRAGE 等牙周炎指标及 BOP 等口腔指标按 5 mm 牙周探诊深度分两组

研究牙周炎指标与口腔指标的关系 **检验与结果**

结果: 口腔指标与测定参数无显著相关关系 如探诊出血

≥ 5 mm 组的 BOP/sRAGE 偏相关系数 $p < 0.05$

调整参数包括: mPPD, PI, sAGE, ESR

讨论: 细分总体可揭示某些规律

**应用实例 黄酒酸度与酿酒红曲米特征关系**

林等, 中国食品学报, 2019.

问题与方法

问题: 红曲米特性对黄酒酸度的影响 pH, 干失重, 容重, 淀粉, 蛋白, 氨基酸, 液化力

研究: 相关与偏相关分析 构建相关系数与偏相关系数矩阵, 含各因素间关系

检验与结果

结果 影响酸度的主要影响因子包括 pH, 蛋白质, 发酵力 等

讨论: 特性参数间相关

偏相关系数能更好反映主要影响因素

	X_1	X_2	X_3	X_4	X_5	X_6	X_7	X_8	X_9	X_{10}	X_{11}
X_1	1	-0.0184	-0.2207	-0.1199	-0.0276**	0.1154	0.4025*	0.1173	-0.3466	-0.1748	0.0737
X_2	0.2813	1	-0.0193	-0.0221	-0.208	0.0151	0.1272	0.0699	-0.0446	0.0508	-0.1475
X_3	-0.3934	-0.0052	1	-0.0161	-0.2207	-0.1199	-0.6210***	0.1091	-0.4475*	0.1193	-0.3546
X_4	0.0119	-0.1437	-0.0369**	1	-0.0276	-0.0199	-0.6210***	0.1091	-0.4475*	0.1193	-0.3546
X_5	0.0119	-0.1437	-0.0369**	-0.0276**	1	-0.298	-0.1919	-0.1919	-0.5413*	-0.1919	-0.5413*
X_6	0.0126	0.0152	-0.4043**	-0.4677*	0.8587**	1	0.0571	0.0402	-0.0113	0.0508	0.0632
X_7	0.4052*	0.0152	-0.4043**	-0.4677*	0.8587**	1	0.3514	0.5668**	0.3906	0.4721*	0.4721*
X_8	0.2696	0.2340	-0.3130	-0.2185	0.0398	0.1081	0.9585**	0.1697	1	-0.0070	-0.5377*
X_9	-0.1311	0.1571	0.1274	0.1507	-0.0358	-0.0476	0.2739	0.0519	0.4618*	1	-0.2510
X_{10}	-0.4343	-0.1603	0.6554	0.4414	-0.3907	-0.3435	-0.7488	-0.3036	0.5133**	-0.2510	1

偏相关系数

相关系数

应用实例 构建评价刊物引用的综合指标

Bradshaw and Brook, Plos One 2016

研究问题与方法

背景: 不同引用指标各有特点 IF, IM, SNIP, SJR, h5/log10

目标: 构建综合评价指标 基于上述指标

数据: 25 个生态学及交叉刊物 κ -再抽样法 vs. 对 188 个科学家调查结果

统计: 相关分析 排序数据的 Spearman 秩相关分析


检验与结果

结果: 显著相关

纵标: 综合指数平均秩 $\pm 95\%$ 不确定性;

横标: 专家调查结果平均秩 \pm 标准差

讨论: 结论? 单一指标呢?

**应用实例 影响伊春河河水溶解态有机碳的因素**

Tao et al., Water Res., 1998

问题

背景: 伊春河河水富含溶解态有机碳 DOC 10-15 mgC/L 沿河多沼泽湿地, 冻土

伊春市主要水源, DOC 是消毒副产物的前体物 CHCl3 等致癌物

研究: 影响河水 DOC 含量的因素

预测消毒副产物水平

方法

数据: 非封冻期日变化数据 DOC, 降水, 流量 Q 等

分析: DOC 和相关参数的关系



应用实例 影响伊春河水溶解态有机碳的因素 *Tao et al., Water Res., 1998*

- 发现**

现象: DOC与流域降水量密切相关 表现为与流量 Q 的同步变化
应用: 用 Q 预测 DOC 很容易通过水位观测获得即时流量 Q
- 结果与讨论**

结果: DOC 与 Q 日数据显著相关 $r = 0.76, p < 0.001$
分析: DOC 变化似乎滞后, 向后错位计算相关系数
错位 8 h, 相关系数达峰值 $r = 0.79$
结论: DOC 变化比 Q 滞后 8 h 湿地滞水与输入
讨论: 潜在应用 – 预测消毒副产物生成量
然后...

应用实例 室内外颗粒物浓度关系 *WHO, 2020*

- 研究背景**

背景: PM_{2.5} 呼吸暴露是最重要的环境风险 2019 导致 120 万例过早死亡
室内暴露主导 成年人平均 86% 时间在室内
室外向室内渗透是室内 PM_{2.5} 主要源 没有强内源的条件下
错觉: 室外: 280-290 $\mu\text{g}/\text{m}^3$, 室内 190-240 $\mu\text{g}/\text{m}^3$ 2015.11.8, 北大逸夫二楼
- 研究方法**

观测: 同步观测室内外 PM_{2.5} 浓度 2013/14 取暖季, 低成本在线传感器
统计: 相关分析

应用实例 室内外颗粒物浓度关系 *Han et al., Environ. Pollut., 2015*

- 结果与检验**

室内外浓度显著相关, 室内滞后 高/低浓度范围的差别
Pearson 相关系数, 时间错位 5 min 步长
冬季平均滞后 75 min 开窗率低
春季平均滞后 115 min

要点

- 多变量方法**
方差, 相关, 回归 目的, 数据, 变量, 联系 ...
- 相关**
正态与非正态
线性与非线性
Pearson, 偏复相关, Spearman 等

应用数理统计方法

第五章 相关与回归分析

- 5.1 二元相关分析
- 5.2 多元相关分析
- 应用举例
- 5.3 一元线性回归
- 5.4 其他回归方法
- 应用举例

多变量研究方法对比 复习 *p.229,292*

- 相关分析**
共变关系 两变量等价
- 回归分析**
模型构建 根据自变量估计或预测因变量
- 方差分析**
影响因素 判断变量是否受某些因素影响

多变量研究方法的关系 复习

p.229,292-242

· 相关分析与回归分析

共同之处 研究两个或多个变量间关系,数据格式相似

不同之处 研究目的,变量关系,变量类型,统计量,检验方法

· 方差分析与回归分析

共同之处 一变量对另一个变量的依赖,变量类型

不同之处 研究目的,变量关系,结果表达,统计量,检验方法,方法应用

方法	相关分析	回归分析	方差分析
研究目的	变量一起变化的程度	构建回归模型 - 估值或预测	研究影响因素
变量关系	两个独立变量	自变量与因变量	独立变量与影响因素
变量类型	均为随机变量	因变量随机,自变量固定或随机	独立变量随机,影响因素固定或随机
统计量	无量纲的相关系数	有单位的回归参数	无描述统计量
检验	相关是否显著	斜率是否显著,模型选择	影响因素是否显著

假设检验问题

p.63

· 特征比较

两总体或多总体大小比较 2.2 – 2.5

两总体或多总体离散程度比较 3.1 – 3.2

两总体分布特征比较 3.4

总体分布是否服从特定理论分布 3.3 – 3.4

· 影响因素

方差分析及补充分析 4.1 – 4.4

· 变量关系

相关分析 5.1 – 5.2

回归分析 5.3 – 5.4

5.3.1

5.3.1 无重复因变量数据的一元线性回归**5.3.2 有重复因变量数据的一元线性回归****回归分析**

p.330

· 回归分析

建立根据自变量预测或估算因变量的统计模型

· 应用

预测: 根据新的自变量值计算对应的因变量值


估值: 对观测数据中已有因变量值均值-置信区间的估计

· 回归分析的模型

模型 I / II, 自变量为固定变量 / 随机效应

类方差分析模型 - 自变量与影响因素参见4.3.1

模型	自变量类型	以估值为目的	以预测为目的
I	固定变量	最小二乘法	最小二乘法
II	随机变量	主轴法, 约化主轴法	最小二乘法

**一元线性回归**

p.331-333

· 一元线性回归


据一个自变量预测/估计一个因变量

因变量为随机变量,自变量是随机或固定变量 二元相关两变量均为随机变量

· 数据无重复因变量数据,一个 x 对应一个 y $x_i, y_i, i = 1 \dots n$ 有重复因变量数据,一个 x 对应若干 y $x_i, y_{ij}, i = 1 \dots n, j = 1 \dots m$ **· 回归方程**

$$\hat{Y} = a + bX, \quad a \text{ 截距 } b \text{ 斜率}$$

模型取决于自变量类型 类似方差分析

**最小二乘法**

p.331-332

· 最小二乘法

用途 构建回归模型 - 模型 I 预测与估值, 模型 II 预测

目标 观察数据到回归方程的垂直距离平方和最小

限定 仅考虑 y 方向上的随机波动

· 数据要求

独立性 对任何给定自变量,因变量独立 即不受其它因变量取值影响


正态性 因变量服从正态分布

最小二乘的合理性

同质性 因变量有相同的方差

加和权重的一致性

理论要求与实际应用的差距?



可决系数

p.331

· 定义

回归平方和与总平方和之比, 记为 r^2 多元回归的可决系数记为 R^2

反映数据与回归方程的吻合程度, 取值在 0 到 1 之间


· 与相关系数的差别

可决系数: 没有对应的总体参数, 不能检验, 不可比较

相关系数: 有对应的总体参数, 可检验, 可比较

$$r = \frac{\sum((x_i - \bar{x})(y_i - \bar{y}))}{\sqrt{\sum(x_i - \bar{x})^2 \sum(y_i - \bar{y})^2}} \text{ 所有点到 } x \text{ 和 } y \text{ 均值的距离}$$

$$r^2 = \frac{(\sum(x_i - \bar{x})(y_i - \bar{y}))^2}{\sum(x_i - \bar{x})^2 \sum(y_i - \bar{y})^2} \text{ 仅 } y \text{ 方向距离}$$



置信区间 复习

p.43

· 置信区间的一般表达

一个区间及该区间包括待估总体参数的概率

$$P\{L_1 \leq \text{总体参数} \leq L_2\} = p$$

L_2, L_1 为该区间的上下界, p 为该区间覆盖总体参数的概率

· 例 算术均值的置信区间

$$P\{L_1 \leq \mu \leq L_2\} = p \quad L_1 = \bar{x} - t_{(p-1)/2} s / n^{0.5}, \quad L_2 = \bar{x} + t_{(p-1)/2} s / n^{0.5}$$


如 $P\{5.5 \leq \mu \leq 6.7\} = 95\%$ 范围 $5.5-6.7$ 包含总体算术均值的概率为 95%

· 应用

点估计的可靠性表达

即区间估计

据预设可靠性估算样本量 见上式, 见下节举例



回归参数的置信区间

p.334-335

· 回归参数的置信区间

截距的置信区间 $P\{L_1 \leq \alpha \leq L_2\} = 1 - \alpha$

斜率的置信区间 $P\{L_1 \leq \beta \leq L_2\} = 1 - \alpha$


估计值的置信区间 $P\{L_1 \leq \hat{y} \leq L_2\} = 1 - \alpha$

预测值的置信区间 $P\{L_1 \leq \hat{y}_{pred} \leq L_2\} = 1 - \alpha$ 预测结果的置信范围, 图中虚线

· 计算

基于标准误差

类比算术均值的标准误差 参见 1.2.5



过原点回归

p.338

· 固定截距的回归

增加固定截距的限定条件 过原点回归是 $a = 0$ 的特例, Excel 中的选项

$$\bar{Y} = bX$$

$a = 0, b$ 为斜率, 拟合方法不变, 拟合效果变差


· 拟合效果描述

可决系数、参数的置信区间 与有截距回归类似

· 应用举例

理论上截距应为零 如分光光度计的归零操作

拟合效果与预测误差 低浓度段误差与可能的负值



回归的显著性检验

p.333

· 可决系数

不可检验 拟合效果的定量描述, 不是对总体参数的估计

仅体现拟合好坏 0 – 1 不反映模型优劣

· 对斜率的假设检验

检验回归模型的斜率 因变量是否有随自变量改变而发生显著变化的趋势


假设 $H_0: \beta = 0, H_1: \beta \neq 0$ β 为总体斜率

用 t-检验 或 方差分析 检验结果显著仅意味着回归直线不是“水平的”

局限性 不代表模型优劣, 不说明模型是否有预测能力

· 错误解释

如“检验结果显著, 模型可用于预测”



斜率比较与公共斜率

不要求 p.348-350

· 回归方程比较

比较多个回归方程的斜率是否有显著差异 同类问题

· 检验方法

两个斜率比较 $H_0: \beta_1 = \beta_2, H_1: \beta_1 \neq \beta_2$ t-检验, 单侧或双侧

多个斜率比较 $H_0: \beta_1 = \beta_2 = \dots = \beta_n, H_1: \beta_1, \dots, \beta_n$ 不都相同 方差分析

· 公共斜率

若检验结果无显著差异, 可计算公共斜率 计算略 参见 5.1.1

· 类比相关分析

相关系数比较与公共相关系数

5.3.2

5.3.1 无重复因变量数据一元线性回归

5.3.2 有重复因变量数据一元线性回归

无重复因变量数据一元线性回归的局限性

p.341

影响拟合效果的因素

选择模型的合理性 是否反映总体自变量与因变量的真实关系?


因变量随机波动大小 因变量变异越大, 拟合结果越差

拟合效果的描述

可决系数 r^2 受模型合理性与随机波动大小两者的共同影响

模型显著性检验

不能区分模型选择与随机波动的影响 没有随机波动信息



课堂讨论


实例讨论

图中哪个模型拟合更好?

前者受随机波动影响大, 后者呈现非线性关系 两者均影响拟合效果

如何区分

没有随机波动信息的情况下, 无法判断 不能判断模型的优劣
只有获得重复因变量数据才能区分两者贡献 类比大小比较的重复数据



无重复因变量数据一元线性回归的局限性


p.341

无重复因变量数据简单回归的局限性

不能区分随机波动和模型合理性两个因素的影响
类比大小比较和方差分析中的随机波动 参见2.2.4, 4.2.1

无重复因变量数据简单回归的结果与应用

结果: 获得既有条件下的最佳拟合
应用: 提供既有条件下的最优估值与预测手段
缺陷: 不能证明模型选取是否合理 无法判断模型优劣
改进: 获得随机波动信息 关注因变量 - 预测需要



有重复因变量数据的一元线性回归

p.341

因变量重复数据

因变量重复数据可提供随机波动信息 模型优劣验证的数据基础


每个自变量取值有 ≥ 2 个因变量取值 允许个别数据缺失 - 方差同质性

无重复 $X_i, Y_{ij}, i=1 \dots n$

有重复 $X_i, Y_{ij}, i=1 \dots n, j=1 \dots m_i$ 类比方差分析 参见4.2.1

计算

拟合及参数计算与无重复回归相同 公式, 回归参数, 可决系数, 置信区间等
可决系数同样不能反映模型优劣



有重复因变量数据回归的假设检验


p.342

检验假设

$H_0: \mu_i$ 都相同 $H_1: \mu_i$ 不都相同 不同自变量取值, 因变量有无差异, 即方差分析
 $H_0: \beta = 0$ $H_1: \beta \neq 0$ 斜率与 0 无显著差异, 与无重复数据回归相同
 H_0 线性关系好 H_1 线性关系不好 是否选择了合适的模型

检验与判断

方差分析方法, 检验顺次进行 体现系统逻辑思路, 第一步可省略
任何一步检验不显著, 即终止 均值有差异不等于斜率为 0
模型优劣通过第三步检验判断 排除因变量随机波动影响的拟合效果



应用数理统计方法

第五章 相关与回归分析

- 5.1 二元相关分析
- 5.2 多元相关分析
- 应用举例**
- 5.3 一元线性回归
- 5.4 其他回归方法
- 应用举例**

回归分析 复习 p.330

- 回归分析**
建立根据自变量预测或估算因变量的统计模型
- 应用**
预测: 根据新的自变量值计算对应的因变量值
估值: 对观测数据中已有因变量值均值-置信区间的估计
- 回归分析的模型**
模型 I / II, 自变量为固定变量 / 随机效应
类比方差分析模型 - 自变量与影响因素参见4.3.1

模型	自变量类型	以估值为目的	以预测为目的
I	固定变量	最小二乘法	最小二乘法
II	随机变量	主轴法, 约化主轴法	最小二乘法

最小二乘法的局限性 p.355

- 最小二乘法**
仅考察垂直方向的随机波动 数据点到回归线的垂直距离
- 最小二乘法的应用**
用于预测与模型 I 估值 自变量为固定处理, 或待预测自变量固定
不适用于模型 II 估值 自变量也是随机变量
- 模型 II 估值方法**
同时考虑两个方向的随机波动

模型	自变量类型	以估值为目的	以预测为目的
I	固定变量	最小二乘法	最小二乘法
II	随机变量	主轴法, 约化主轴法	最小二乘法

以估值为目的的模型 II 回归 p.355

- 最小二乘**
最小二乘法不适用 A-B 到拟合线距离最短, 垂直于 X 轴
- 模型 II 回归估值**
主轴法, 最小正交平方法 A-C 到拟合线距离最短, 垂直于回归线, 两变量权重?
约化主轴法 考虑变量尺度差异, 基于标准化的主轴法
等分线 A-D 到 X 和 Y 方向两条垂线的夹角平分线
夹角平分线 X, Y 互换做两次最小二乘, 取两个方程的夹角平分线

非线性回归 p.361-363

- 基于特定理论的非线性回归**
已知理论方程, 根据观测结果获得拟合参数 可检验假设理论
如一级反应动力学 C - 浓度, C_0 - 初始浓度, k - 速率常数, t - 时间
应用: 获取相关参数, 构建预测方程, 验证特定机理
- 基于经验的非线性回归**
根据观测数据寻找合适的方程形式 试算 = 凑
常用曲线方程举例
应用: 构建预测方程

曲线	方程
幂函数	$\hat{Y} = aX^b$
指数函数	$\hat{Y} = ae^{bX}$
对数函数	$\hat{Y} = a + b\log X$
双曲线函数	$\hat{Y} = a + b/(X+c)$
S 函数	$\hat{Y} = 1/(1+aX^b)$
n 次多项式	$\hat{Y} = a_0 + a_1X + a_2X^2 + \dots + a_nX^n$

多项式回归 p.362

- 多项式拟合**
一元 m 次多项式公式 $= b_0 + b_1x + b_2x^2 + \dots + b_mx^m$
常用非线性方法, 使用灵活
不能为追求拟合效果任意增加阶数 例: 随机生成的一组数据

X	Y
0.01	0.73
0.01	0.14
0.02	0.42
0.10	0.24
0.10	0.04
0.29	0.15
0.46	0.75
0.46	0.26
0.47	0.59
0.51	0.79
0.58	0.30
0.61	0.60
0.63	0.04
0.64	0.04
0.66	0.41
0.67	0.81
0.81	0.97
0.85	0.95
0.90	0.24
0.99	0.02

多元回归

不要求

多元线性回归

一个以上自变量的线性回归 $\hat{Y} = a + b_1X_1 + \dots + b_nX_n$

计算与检验 类似一元线性回归


可决系数与调整可决系数 R^2 与 R^2_{adj} , 后者可消除自变量增加造成的偏离

标准化多元回归 自变量标准化以消除尺度差异的影响

多元非线性回归

类似一元非线性回归

如曲面拟合



非参数回归 - 顺序检验

p.366

非参数回归

顺序检验, 粗略判断动态变化的简单趋势 不是本来意义上的回归


自变量为时间的 Spearman 秩相关分析 本质上是非参数相关

检验

假设: 某变量是否有显著的动态变化趋势 随时间升降的一般趋势

应用举例

判断空气质量多年变化的一般趋势



回归的不确定性表征

p.332

主要指标

可决系数 Coeff. of determination


回归系数的置信区间 斜率, 估计值, 预测值

归一化平均偏差 Normalized mean bias

归一化平均误差 Normalized mean error

均方根误差 Root mean square error

y 观测因变量, 计算因变量, 预测因变量 观测因变量均值 观测自变量均值




更多图示举例

举例

多种参数并用 观测 vs 模型估计

多重置信区间 观测, 预测, 置信区间

参数空间分布 模型的 R^2 , NME, RMSE



回归结果图示

区分两类散点图


回归: 因变量 / 自变量 可包含回归方程, 和各类误差表达

验证: 预测值 / 观测值 1:1直线, 虚线误差范围, 颜色分类, 大小样本量等

常见错误举例

预测值 / 观测值 散点图 使用没有意义的拟合直线或可决系数

非正态分布数据 常见非正态分布, 特别是对数正态分布例子 参见下页



对数正态分布数据举例及模拟


对数正态分布

常见 微量污染物浓度, 风速, ...

基于原始数据回归的偏斜 高值点拟合权重贡献过高

基于对数变换数据的回归

结果更合理 有时也能改善拟合效果



多变量研究方法对比 复习 p.229,292

- 相关分析**
共变关系 两变量等价
- 回归分析**
模型构建 根据自变量估计或预测因变量
- 方差分析**
影响因素 判断变量是否受某些因素影响

方法	相关分析	回归分析	方差分析
研究目的	变量一起变化的程度	构建回归模型 - 估值或预测	研究影响因素
变量关系	两个独立变量	自变量与因变量	独立变量与影响因素
变量类型	均为随机变量	因变量随机, 自变量固定或随机	独立变量随机, 影响因素固定或随机
统计量	无量纲的相关系数	有单位的回归参数	检验统计量 F

应用数理统计方法

第五章 相关与回归分析

- 5.1 二元相关分析**
- 5.2 多元相关分析**
- 应用举例**
- 5.3 一元线性回归**
- 5.4 其他回归方法**
- 应用举例**

应用实例 据教育水平等参数预测死亡率 Muller, BMJ, 2002

- 问题与方法**
背景: 人群死亡率与代表性社会经济因素有关 基尼指数, 人均收入, 教育水平
目的: 构建用相关参数预测死亡率的模型 基于美国州数据
- 结果和讨论**
假设: $H_0: \beta = 0$ 自变量不会影响人群死亡率
结果: 拒绝原假设 其中单一教育因素的预测能力最强 $r^2_{adj} = 0.54$
增加另两个因素不能提高预测能力
讨论: 自变量相关

应用实例 据显示器销售量预测回收量 许等, 厦大学报, 2017

- 问题与方法**
目的: 根据某品牌显示器累积销售量预测累积回收量
数据: 收集典型数据 显示器 E1913c
方法: 建立回归模型: 回收量 = $0.00487 \times$ 销售量 - 60.57
- 结果和讨论**
检验: $H_0: \beta = 0, H_1: \beta \neq 0, F > F_{0.05}$ 拒绝 H_0 , 可用销售量预测回收量
讨论: 不合理截距 过原点回归
检验结论 无重复数据, 不能检验是否具线性关系
进行 F 检验, 若两变量没有线性相关性则认为回归系数 β_1 等于零, 否则不等于零, 提出零假设和备择假设
 $H_0: \beta_1 = 0, H_1: \beta_1 \neq 0$
方差分析结果如表 I 所示, 由于 $F > F_{\alpha=0.05}$, 则拒绝原假设 (因此 X 和 Y 具有线性关系)

应用实例 据人均GDP预测机动车黑炭排放因子 Wang et al., Environ. Atom., 2012

- 问题与方法**
背景: 机动车黑炭排放因子 EF_{BC} 单位质量耗油排放的黑炭量
目的: 构建 EF_{BC} 数据库和模型, 预测各国汽车排放量
- 结果和讨论**
发现: 人均 GDP_c 是很好的预测变量 $\log EF_{BC} = k GDP_c + C$
注意到对发展中国家的高估 左图中黑色三角符号
改进: 引入变量 Y_{3000} 达到 \$3000 年份 $\log EF_{BC} = k GDP_c + a Y_{3000} + C$
解释: 证实了发展中国家的后发优势 学习了发达国家的管理和技术

应用实例 据价格等参数预测土焦产量 Xu et al., PNAS 2018

- 问题与方法**
背景: 土法炼焦是最重要的污染物排放源之一 1998 年被禁, 2011 年消失
目的: 评估禁止土法炼焦的健康效益 PM_{2.5} 和苯并芘两类污染物
方法: 利用遥感数据, 估算 1982-2015 土焦产量
- 结果和讨论**
建模: 禁止焦, 基于历史数据的多元线性回归 焦炭, 煤, 钢产量和焦炭价格
土焦 = $0.96P_{coal} - 0.15P_{coal} - 0.39P_{steel} - 0.78 Price_{coal} + 170 R^2_{adj}=0.98$
估算: 三种情景的产量, 排放和健康危害 真实, 不禁, 1998 立即终止
结果: PM_{2.5} 导致的过早死亡 实际 36.6 万, 无禁焦 106 万, 98 年禁 18 万

应用实例 据社会经济参数预测生活能耗季节变化 Chen et al., Appl. Energy 2016

问题与方法

目的: 构建全球生活能耗模型, 预测季节变化 全球国家级年数据, 极少季节数据


结果和讨论

假设: 能耗时-空变化受控于同样因素 HDD, CDD, 人均 GDP, 住房面积等

方法: 时空置换: 用空间数据建模, 预测动态变化 多元线性回归

模型: 区分国家类别 6个燃料模型和5个电能模型

验证: 空间与动态验证 9组季节模拟验证



应用实例 据流量预测河水溶解态有机碳含量 Tao et al., Water Res., 1998

问题与方法

背景: 发现伊春河河水 DOC 含量与河水流量显著相关, 滞后 8 小时

目的: 根据上述关系预测 DOC 含量 继而预测供水中消毒副产物前体物浓度


结果和讨论

结果: 比较两个回归模型

$$\text{直接回归 } \text{DOC}_t = \frac{a}{Q_t + 154.6}$$

$$\text{滞后 8 小时回归 } \text{DOC}_{t+8} = \frac{a}{Q_t + 136.0}$$

讨论: 对数变换



应用实例 模拟大气定向被动采样器的定向效果 Tao et al., Environ. Pollut. 2008

问题与方法

背景: 来自不同方向气团的污染物浓度可能不同 源区方向

目的: 研制大气定向被动采样器 采集四个方向气团样品, 测定多环芳烃


设计: 屏蔽侧向气流的定向口设计 防侧风

研究: 风向 d 对流速 V 影响实验 测定入风 $\pm 45^\circ$ 范围内的衰减率 V_d/V_0

结果和讨论

拟合: 非线性 $\frac{V_d}{V_0} = \frac{1}{1 + (\frac{d}{30})^{0.72}} \quad r^2 = 0.974$ d 超过 30° 明显衰减

讨论: 缺少对比



应用实例 据闪电密度预测闪电致死风险 Roeder et al., Nat. Hazards, 2015

问题与方法

目的: 根据人口加权闪电密度预测闪电致死密度 云地闪电

数据: 1997-2010 全美数据


结果和讨论

拟合: 线性回归 $y = 3.21 \times 10^{-6}x + 8.95 \times 10^{-5} \quad r^2 = 0.820$

二项回归 $y = 5 \times 10^{-9}x^2 + 5 \times 10^{-6}x + 6 \times 10^{-5} \quad r^2 = 0.864$

讨论: 数据分布 - 尖峰右偏, 基于对数变换的回归

二项式的不合理非单调变化



应用实例 据人均收入预测农村居民清洁炊事占比 Tao et al., Nature Energy, 2018

问题与方法

背景: 中国农村居民直接能源结构发生显著变化 炊事清洁能源占比上升

数据: 农村居民 1992-2012 年能源结构 34,000 多户入户调查

目的: 分析影响变化的主要驱动因素 清洁能源占比 Fe


结果和讨论

因素: 可负担性人均收入 I_{cap} 主导, 可获取性秸秆和煤炭产量有较小影响

模型: 人均收入为预测变量 $\log Fe = -62.4 + 62.6(1 - e^{-1.324 \log I_{cap}}), \quad r^2 = 0.878$

结果: 能源结构转变的优势驱动因素 87.8%

用途: 可预测时空变化趋势



应用实例 据分子量预测多环芳烃被动采样效率 Tao et al., ES&T 2007

问题与方法采样

背景: 被动采样器采集大气多环芳烃 16 种多环芳烃, 引入分子量参数 MW_A

数据: 主动和被动采样器同步采样 A 主动; P 被动

方法: 构建校验模型 气态与颗粒态分别拟合

结果和讨论


气态: $\log PAH_A = 0.77 \log PAH_P - 2.2 \times 10^{-9} MW_A^{3.8} + 1.62 \quad r^2 = 0.880$

颗粒: $PAH_A = PAH_P / e^{3.70 - 0.0314 MW_A} \quad r^2 = 0.877$

PAH_A 主动采样浓度

PAH_P 被动采样浓度

MW_A 分子量



应用实例 据服务型领导和自我效能预测服务质量 Qiu et al., *Tour. Manag.* 2020

问题与方法

目的: 研究服务型领导 X 与自我效能 Y 对服务质量 Z 的影响
数据: 673 个餐馆和 317 个酒店雇员问卷调查打分数据 餐馆与酒店

结果和讨论

假设: 服务型领导与自我效能对服务质量无显著影响 二元/多项式回归
餐馆: $Z = b_0 + b_1 X^{**} + b_2 Y^{**} + b_3 X^2 + b_4 XY^{**} + b_5 Y^{2**}$ $R^2=0.333/0.342$
酒店: $Z = b_0 + b_1 X^{**} + b_2 Y^{**} + b_3 X^2^{**} + b_4 XY^{**} + b_5 Y^2$ $R^2=0.333/0.342$

讨论: 影响?

应用实例 模拟土壤水溶性有机碳的淋出过程 Tao et al., *WASP. 2000*

问题与方法

背景: 土壤结构 非均相系统, 有机矿物复合体-土壤团粒
土壤水分 重力水和毛管水分别指土壤团粒间和团粒内的水
目的: 定量分析土壤剖面中水溶性有机碳的淋出过程 土柱模拟实验

结果和讨论

拟合: 一次动力学负指数曲线拟合, 有明显偏离 肩, 折点, 常数项
机理: 多步过程 三项加和: 对流-高斯, 扩散-负指数, 解吸-负指数
讨论: 对假设过程的定量证明

要点

多变量方法
方差, 相关, 回归 目的, 数据, 变量, 联系 ...

相关
正态与非正态, 线性与非线性 Pearson, 偏相关, Spearman 等

回归
预测与估值
一元线性回归, 无重复因变量 可决系数, 置信区间, 不确定性, 局限性
一元线性回归, 有重复因变量 可检验拟合优劣
其它 过原点, 多元, 多项式, 非线性 ...

谢谢